



HOCHSCHULE HEILBRONN

# ENTWICKLUNG EINES PHYSIKBASierten CHARAKTERCONTROLLERS MIT UNITY ML AGENTS

**Software-Engineering**  
Fakultät für Informatik  
der Hochschule Heilbronn

## **Bachelor-Thesis**

vorgelegt von

**Simon Grözing**  
Matrikelnummer: 205047

# Inhaltsverzeichnis

<b>1</b>	<b>Einleitung</b>	<b>4</b>
<b>2</b>	<b>Verstärkendes Lernen</b>	<b>5</b>
<b>3</b>	<b>MI-Agents</b>	<b>6</b>
3.1	Komponenten . . . . .	7
3.1.1	Verhalten . . . . .	8
3.1.2	Entscheidung . . . . .	8
3.1.3	Agent Abstrakte Funktionen . . . . .	9
<b>4</b>	<b>Versuche</b>	<b>11</b>
<b>5</b>	<b>Fazit</b>	<b>12</b>

# Abbildungsverzeichnis

2.1	Verstärkendes Lernen Ablauf [2] . . . . .	5
3.1	Unity ML-Agents Lernumgebung [3] . . . . .	6
3.2	Unity ML-Agents Lernumgebung Beispiel [4] . . . . .	7
3.3	Unity ML-Agents Verhalten Komponente . . . . .	8
3.4	Unity ML-Agents Entscheidung Anfragen Komponente . . . . .	8

# 1 Einleitung

Machine Learning Modelle bieten neue Möglichkeiten den Prozess der Charakter animation zu erleichtern. In der Thesis soll ein Ansatz anhand bestehender Literatur und Beispiele erforscht werden, in dem Spielcharaktere physikalisch mit Rigidbodies und Joints simuliert und mit Hilfe von Machine Learning trainiert werden, um möglichst realistische Bewegung nachahmen zu können.

## 2 Verstärkendes Lernen

Der Begriff 'Verstärkendes Lernen' beschreibt eine Art von Problemstellung und die dafür geeigneten Problemlösungsmethoden im Bereich des Maschinellen Lernens. Die grundlegenden Bestandteile einer Trainingsumgebung sind der Agent und die Umgebung, in der der Agent seine Aktionen ausführt. Der Ansatz ist in vielerlei Hinsicht vergleichbar mit dem Lernvorgang von Menschen. Ein Baby lernt das Krabbeln ohne direkte Anweisungen, nur durch die Wahrnehmung der Umgebung, das Verhalten der Umgebung in Relation zu seinen Bewegungen und die mit den Bewegungen einhergehenden Belohnungen. Auf dieselbe Art lernt der Agent beim Verstärkenden Lernen von jedem Zustand die Aktion auszuführen, um die Belohnung zu maximieren. Im Fall des Babys sind die Belohnungen Faktoren wie Schmerz, Hunger, Müdigkeit oder gestillte Neugier. Der Agent hingegen erhält eine numerische Belohnung.[1]




Abbildung 2.1: Verstärkendes Lernen Ablauf [2]

Die Abbildung 2.1 zeigt die Verbindungen zwischen dem Agent und der Umgebung. Der Agent erhält als Input einen Zustand oder meist einen Teilzustand der Umgebung und reagiert darauf mit einer Aktion. Dieser Zyklus kann je nach Problem in unterschiedlichen Intervallen durchlaufen werden. Bei kontinuierlichen Kontrollproblemen werden Aktionen meist in regelmäßigen Intervallen abgefragt. Bei rundenbasierten Spielen kann dieser Vorgang jedoch auch nur einmal pro Runde stattfinden.

### 3 ML-Agents

Das Unity ML-Agents Toolkit ist ein Open-Source-Projekt, in dem maschinelle Lernalgorithmen und Funktionen für die Verwendung mit der Spieleumgebung Unity implementiert und kontinuierlich weiterentwickelt werden. Die Implementierung ist in zwei Bereiche unterteilt. Für die Unity-Integration ist das Paket `com.unity.ml-agents` aus dem Unity Asset Store zuständig. Das eigentliche Training mit den maschinellen Lernalgorithmen findet jedoch in einer separaten Python-Umgebung statt. Für die Kommunikation zwischen den beiden Bereichen verwendet das ML-Agents Toolkit eine C# Kommunikator-Klasse, die über gRPC-Netzwerkcommunication mit dem Python-Prozess kommuniziert. Der Python-Prozess kommuniziert über die Python Low-Level-API, die die Kommunikation übernimmt und die Befehle an den Trainer weiterleitet.[5]

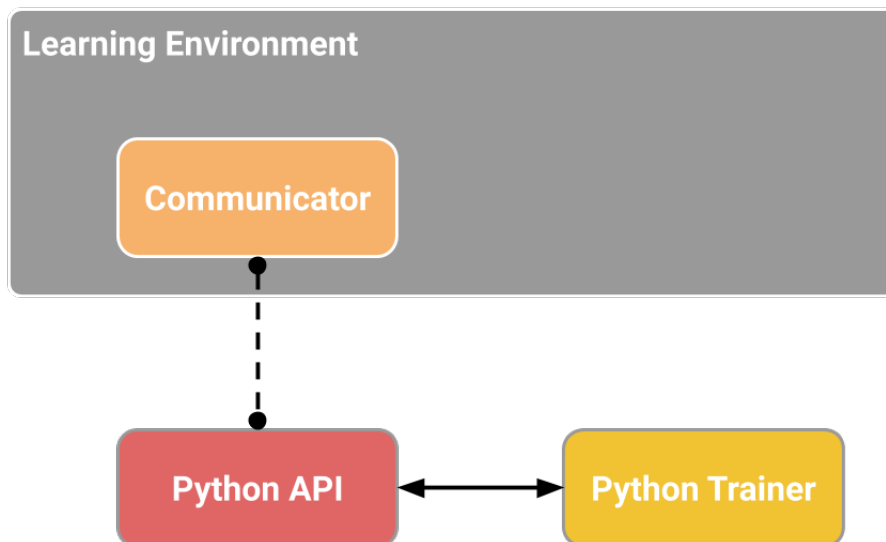


Abbildung 3.1: Unity ML-Agents Lernumgebung [3]

Das Unity-Paket enthält zwei Komponenten: Agenten und deren Verhalten. Die Agent-Komponente bildet die Grundlage für alle Implementierungen. Sie bietet abstrakte Funktionen für die Initialisierung, den Start einer Episode, das Erfassen des Zustands der Umgebung sowie das Ausführen von Aktionen. Durch die Implementierung dieser Funktionen können unterschiedlichste Agenten entwickelt und trainiert werden. Jeder Agent ist mit einem Ver-

halten verknüpft, das für jede Beobachtung des Agenten eine Aktion auswählt, die der Agent ausführt. Es gibt drei Arten, wie die Verhaltensweisen agieren können. Im Lernmodus werden die Beobachtungen des Agenten für das Training und die Auswahl einer Aktion anhand des aktuellen Modells verwendet. Der Inferenzmodus nutzt hingegen ein bereits trainiertes Modell und wertet dieses aus. Der letzte Modus eines Verhaltens ist der Heuristikmodus, bei dem festgelegte Regeln im Code entscheiden, welche Aktion ausgeführt wird, ohne die Verwendung eines trainierten Modells.[5]

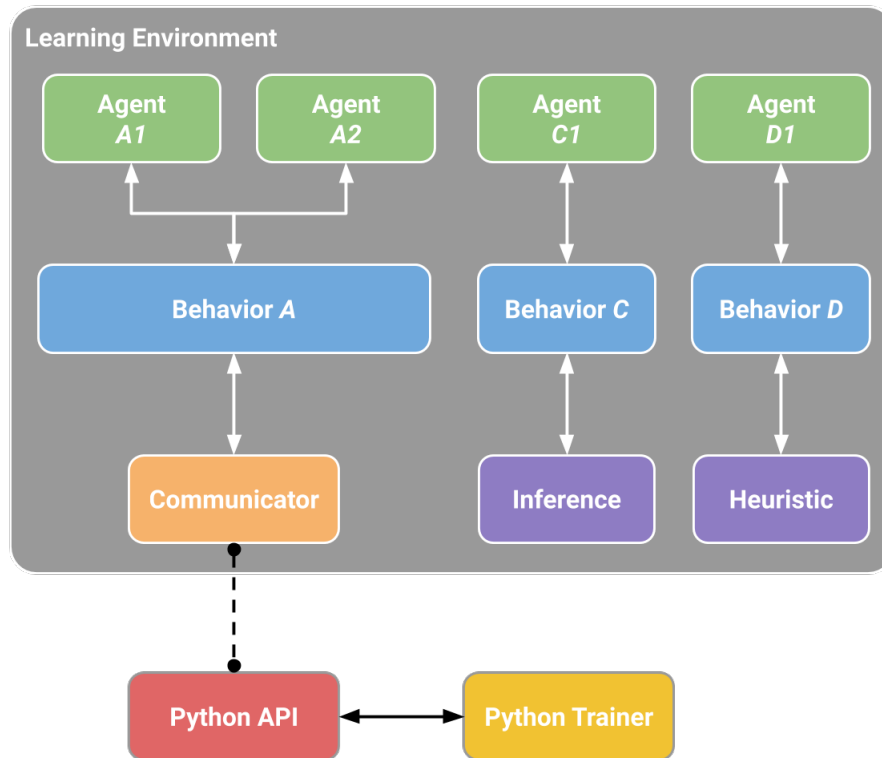


Abbildung 3.2: Unity ML-Agents Lernumgebung Beispiel [4]

## 3.1 Komponenten

In diesem Kapitel werde Ich die Grundlegenden Komponenten des Unity ML-Agents Packets, welche in der Arbeit verwendet wurden erklären. Dadurch sollten Codeausschnitte und Komponentenabbildungen in folgenden Kapiteln deutlich zu verstehen sein.

### 3.1.1 Verhalten

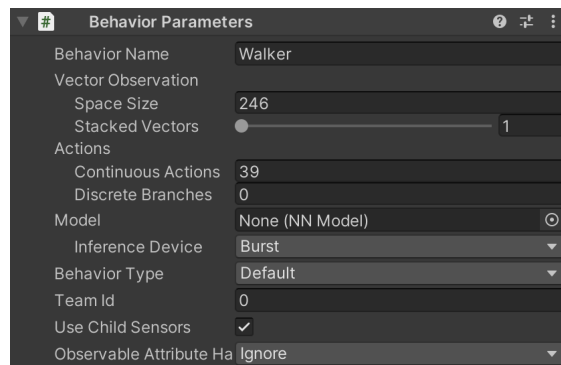


Abbildung 3.3: Unity ML-Agents Verhalten Komponente

Konfigurationsfeld	Beschreibung
Behaviour Name	Name des Verhaltens / wird in Trainer Konfiguration referenziert
Space Size	Anzahl an Beobachtungen / Inputknoten für NN
Continuous Actions	Anzahl an Aktionen / Outputknoten von NN
Model	Referenz auf bereits trainiertes Modell zur Verwendung in Inferenz
Behaviour Type	Lernmodus Default = Lernen, Heuristic, Inferenz

### 3.1.2 Entscheidung




Abbildung 3.4: Unity ML-Agents Entscheidung Anfragen Komponente

Konfigurationsfeld	Beschreibung
Decision Period	Anzahl an Akademie-Schritten (standard ein Schritt pro Physikupdate) bis zur nächsten Entscheidung
Take Actions Between Decisions	Kontrollkasten ob Agent Aktionen zwischen Entscheidungen ausführen soll



### 3.1.3 Agent Abstrakte Funktionen

Die Akademie stellt mit dem Attribut `EnvironmentParameters` die Umgebungsparameter aus Trainer Konfiguration oder aktueller Lektion bereit

```
1 envParams = Academy.Instance.EnvironmentParameters;
```

Mit dem `StatsRecorder` lassen sich Daten aggregieren um diese nach oder während dem Training über die Tensorboard Visualisierung auszuwerten

```
1 statsRecorder = Academy.Instance.StatsRecorder;
```

In der `CollectObservations` Methoden wird festgelegt welche Daten dem Agent für das Training bereit stehen, dieser Schritt wird für jede angefragte Entscheidung ausgeführt und das Ergebnis an das NN Modell oder den Python Trainer übergeben.

```
1 public override void CollectObservations(VectorSensor sensor)
2 {
3     sensor.AddObservation(floatObservation);
4 }
```

Wenn eine Entscheidung angefragt wurde und das NN Modell ein Ergebnis liefert wird dieses hier von numerischen Werten in Aktionen umgewandelt.

```
1 public override void OnActionReceived(ActionBuffers actionBuffers)
2 {
3     var continuousActions = actionBuffers.ContinuousActions;
4     float action = continuousActions[0]
5 }
```

Im folgenden Beispielcode wird ein Reward in jedem `FixedUpdate` vergeben über die `AddReward` Methode die auch Teil der Agenten-Komponente ist. Der Reward kann aber an jeder Stelle im Code vergeben werden, der Code dient hier nur als ein Beispiel.

```
1 public virtual void FixedUpdate()
2 {
3     AddReward(floatReward);
4 }
```

Die Trainings Konfigurationsdatei enthält mehrere Teile. Der hyperparameter Teil enthält die Hyperparameter des Maschinellen Lernalgorithmuses, danach folgt der `network_settings` Teil welcher die Konfiguration des Neuronale Netztes festlegt. Anschließend folgen noch Konfigurationen für die Belohnungssignale im Bereich `reward_signals` und Einstellungen für die

Speicherung der Daten sowie der länge des Trainings. Ganz am Ende der Konfigurationsdatei befinden sich noch Umgebungsparameter welche erweitert und während dem Training ausgelesen werden können.

```
1 {
2 behaviors:
3   Walker:
4     trainer_type: ppo
5     hyperparameters:
6       batch_size: 2048
7       buffer_size: 20480
8       learning_rate: 0.0003
9       beta: 0.005
10      epsilon: 0.2
11      lambd: 0.95
12      num_epoch: 3
13      learning_rate_schedule: linear
14    network_settings:
15      normalize: true
16      hidden_units: 256
17      num_layers: 3
18      vis_encode_type: simple
19    reward_signals:
20      extrinsic:
21        gamma: 0.995
22        strength: 1.0
23    keep_checkpoints: 5
24    checkpoint_interval: 5000000
25    max_steps: 30000000
26    time_horizon: 1000
27    summary_freq: 30000
28  environment_parameters:
29    environment_count: 100.0
30 }
```

## 4 Versuche

Text

## 5 Fazit

Text

# Literaturverzeichnis

- [1] Richard S Sutton und Andrew G Barto. *Reinforcement learning: An introduction*. MIT press, 2018.
- [2] Unity. *rl cycle*. 27.02.2018. URL: [https://github.com/Unity-Technologies/ml-agents/blob/release\\_21/docs/images/rl\\_cycle.png](https://github.com/Unity-Technologies/ml-agents/blob/release_21/docs/images/rl_cycle.png).
- [3] Unity. *unity mlagents learning environment*. 29.04.2020. URL: [https://github.com/Unity-Technologies/ml-agents/blob/release\\_21/docs/images/learning\\_environment\\_basic.png](https://github.com/Unity-Technologies/ml-agents/blob/release_21/docs/images/learning_environment_basic.png).
- [4] Unity. *unity mlagents learning environment example*. 29.04.2020. URL: [https://github.com/Unity-Technologies/ml-agents/blob/release\\_21/docs/images/learning\\_environment\\_example.png](https://github.com/Unity-Technologies/ml-agents/blob/release_21/docs/images/learning_environment_example.png).
- [5] Unity. *unity mlagents toolkit overview*. 6.06.2023. URL: [https://github.com/Unity-Technologies/ml-agents/blob/release\\_21/docs/ML-Agents-Overview.md](https://github.com/Unity-Technologies/ml-agents/blob/release_21/docs/ML-Agents-Overview.md).